马晨恩　**求职意向：AI 技术产品经理**

| 电话：13121213769 | 邮箱：m640302@163.com | 所在地：上海

核心优势

复合学术背景，本硕毕业于北京航空航天大学+东京工业大学，辅修应用数学，具备扎实的数理统计与机器学习功底；以一作发表 SCI 二区论文，拥有 1 项授权发明专利，具备复杂系统算法创新与建模能力。4 年头部企业技术产品全生命周期管理经验，覆盖从需求调研、产品规划、PRD 输出、版本迭代到规模商用的全流程。拥有大模型开发、算法商用落地等 B 端企业级解决方案的实战经验。

一、教育背景

东京工业大学　　| 工业工程与经济 工学硕士 |　　2020.04-2022.04

- 所获荣誉：东京工业大学全额奖学金、日本 JASSO 留学奖学金

北京航空航天大学　| 管理科学与工程 工学学士 |　应用数学（辅修）　理学学士 |　　2015.09-2019.06

- 所获荣誉：校级优秀毕业生、学科竞赛奖学金二等奖、冯如杯数理竞赛三等奖、全国项目管理竞赛全国二等奖

二、工作经历

华为技术有限公司　海思图灵解决方案开发部 | 大模型算子开发　　2025.08-现在

- 工作内容概述：主导千亿级大模型算子开发、推理性能调优与硬件适配，负责 Flash Attention 系列算子的功能实现、精度对齐与性能优化，支撑字节跳动豆包大模型商用上线；构建算子硬件性能理论模型，为大模型推理优化提供核心技术支撑。

华为技术有限公司　SRAN 解决方案开发部 | 智能算法产品经理 SE　　2022.06-2025.08

- 工作内容概述：负责通信网络智能化产品的全生命周期管理，开展运营商客户需求调研分析，输出算法产品端到端解决方案；完成需求拆解、项目管控、算法技术验证与落地；建立标准化产品需求管理体系，推动产品从试点验证到规模商用全流程落地。

三、项目经历

1、大模型推理性能优化与算子基建项目 | 开发者工具负责人 |　　2025.08-现在

- **需求背景：**针对千亿级大模型商用落地面临的推理性能瓶颈、算子硬件性能黑箱化、开发迭代周期长等核心行业痛点，先后主导负责字节跳动豆包千亿大模型推理性能调优、基于 PYPTO 的 FIA 融合推理注意力算子开发调优、FA 算子全量化性能建模三大核心模块。
- **过程与核心贡献：**

1）算子性能建模产品：基于 FA 计算逻辑的全量化硬件性能分析工具，无需编写 Ascend C 代码即可精准预估算子硬件性能。基于 Roofline 模型完成 FA、GQA/MLA/PA 等主流大模型算子的计算-访存全流程拆解，建立算子理论性能上限数学模型；覆盖全位宽、多粒度、多算法的量化策略，完成量化场景下的算子性能映射建模，针对昇腾芯片完成向量、矩阵运算指令的 cycle 级性能摸底。工具可通过量化-分块-硬件协同优化锁定最优方案，精准定位计算/ 带宽 / SRAM 瓶颈，大幅降低算子开发试错成本。

2）算子开发调优与 agent：主导 CANN 套件 PYPTO 的 FA 系列算子全流程开发，适配 GLM-4 \DS32 等主流大模型复杂注意力架构（PFA/IFA/SFA/MLA/LI），完成功能原生重构、rtol<0.05 级精度全量验证。通过 Tile 分块精细化优化、硬件亲和性调优、因果注意力架构重构等攻坚，突破初始版本性能不足原生算子 0.6 倍的瓶颈，最终性能达标。沉淀标准化开发流程，研发全流程开发技能自动化算子开发 Agent，实现端到端提效。

3）字节跳动驻场豆包大模型性能调优项目：豆包大模型 M9 在 10k 长序列场景下的单卡吞吐、推理延迟等指标不足，且昇腾算子适配验证、多模块协同优化存在诸多难点。项目中支撑 A3 芯片在大 EP Decode 方舟上线及模型商用落地，聚焦豆包 M9 大模型完成全链路性能优化。项目中先完成 M9 模型性能专项攻坚，解决 IPC 与 cachemiss 关联影响、内存管理优化等问题，将推理任务下发耗时从 70ms 降至 8ms，在 10k 长序列场景下实现单卡 TPS 达 1710，超额完成 1700 + 的目标，autoeval 跑分达 65。同时完成客户自定义算子集适配，跑通开源中间层 XpuGraph，实现 eager 与 compile 模式张量精度一致。此外，叠加服务化框架完成 MTP、多机分布式、PD 分离等多维度优化，形成全链路优化方案。

- **项目成果：**性能建模实现理论性能预估与实测值误差≤15%，将算子开发迭代周期从 7 天压缩至 1 天以内；基于 pypto 开发的 FIA 算子性能达 ascendC 基准 0.6 倍；豆包大模型调优实现单卡 TPS1700+，支撑千亿级模型全量商用上线。

2、基站智能供配电算法产品化项目 | 算法产品负责人(产品经理) |　　2024.05-2025.05

- **需求背景：**针对运营商基站配电改造成本高、周期长、电源实际利用率不足 50%、功率秒级波动易引发跳闸的行业共性痛点，现有方案无法平衡供电安全、网络质量与改造成本，难以兼顾降本增效与风险防控，需打造智能化供配电算法产品，实现精细化配电管控。
- **过程：**作为核心算法产品研发负责人，全流程主导项目需求拆解、算法架构设计、模型训练与迭代、样机验证、工程化算力优化及知识产权申报工作。项目分两大核心模块闭环推进：先完成秒级按需供电算法研发与样机验证，再落地小时级按需配电算法，同步攻克百 GB 级行业数据处理与高复杂度寻优的算力瓶颈，最终完成全方案验收与专利申报。
- **算法贡献：**负责构建 “负载预测 - 功率预测 - 最优分配 - 反馈优化” 全链路算法体系。

1）按需供电算法：采用卡尔曼滤波实现秒级小区负载预测，平均预测误差 6.5%；搭建四层 MLP 模型实现射频模块秒级功率预测，拟合优度 92%、平均误差 1.34%；基于 SLSQP 算法求解带电源硬约束的谱效损失最小化优化问题，保障功率分配的实时性与最优性；设计动态冗余反馈机制，大幅提升系统鲁棒性。

2) 按需配电算法：构建 MLP 模型实现 4/5G 小区小时级负载分布统一建模，拟合优度 97%；设计 “差分进化+局部优化”混合寻优策略，搭配随机抽样方案解决多载波多模块场景的算力瓶颈；优化分布式计算架构，解决百 GB 级数据 CPU 处理的内存溢出与并行锁冲突问题。

- 结果：

1）核心指标全面超预期：秒级功率锁实现基站 100% 不超载，忙时电源利用率达 98%，功率预测综合误差 0.4%，谱效损失预估平均误差 3.8%，均远超验收标准；在 5% 谱效损失容忍度内，实现 30% 的配电量压缩。

2）工程效率实现量级提升：数据清理效率从天级优化至小时级，配电策略寻优时间从天级压缩至秒级，完全满足实时性业务要求。

3）知识产权落地：核心方案已获得发明专利授权，专利号：202510828251.7。成为华为 SRAN 核心智能化产品，带来商业收入。

3、前传隐患业务影响量化评估及智能修复方案项目 | 算法产品负责人(产品经理) | 2024.12-2025.08

- 需求背景：通信网络传统被动式运维模式下，前传类故障工单占比高，行业核心痛点为无法量化前传误码对频谱效率、用户下行速率的实际业务影响，导致隐患治理无科学优先级，运维人力投放低效，难以实现故障事前预防。

- 过程：作为项目核心算法产品与方案负责人，全流程主导需求拆解、核心算法模型设计、数据采集与预处理体系搭建、模型训练迭代、实验室与现网验证、全流程治理方案设计及 Beta 落地工作。项目围绕 “量化评估 - 优先级排序 - 隐患定位 - 修复验证” 全链路闭环推进，完成双核心量化模型研发、配套工程化方案设计与现网落地验证，同步规划隐患修复算法孵化路径。

- 算法贡献：

1) 研发用户级秒级前传误码-谱效影响量化 MLP 模型，采用控制变量法隔离干扰因素，创新用户抽样 + 流量加权的小区级结果汇总方案，在降低 90% 以上算力负载的同时，保障预测精度，解决了用户分布差异导致的小区级评估精度不足问题。

2）搭建谱效-下行速率映射 MLP 模型，解耦用户级精度评估与小区级体验量化，为一线运维提供可落地的判断依据。 设计误码触发式检测机制，减少 93% 的无效计算与冗余存储；创新影子模式部署方案，解决模型迭代的数据瓶颈与现网部署风险，配套完成隐患治理优先级排序体系与秒级数据时间对齐方案。

- 结果：

1）核心模型精度超验收标准：谱效影响量化平均相对误差 0.9%、下行速率预测误差 < 10%，拟合优度 R^2 达 0.8。

2）完成杭州内场理想环境验证与 10 个典型现网站点 Beta 全流程验证，全功能模块顺利通过验收，实现运维模式从被动响应到主动预防的升级，方案已规模应用于浙江移动等运营商局点，有效强化了华为维保服务的数据化运维能力与市场核心竞争力。

4、华为键鼠穿越及打印机智能化项目 | 智能硬件特性产品经理 | 2022.06-2022.11

- 需求背景： 为完善华为智能办公硬件生态布局，打破传统打印行业智能化程度低、用户核心痛点解决不足、产品需求管理无标准化体系的行业困境，参与华为激光打印机新品从 0 到 1 的需求定义，针对行业通用共性痛点，完成特性创新与技术落地。

- 实现过程和核心贡献：深入企业、医院、学校等核心场景挖掘需求，输出全场景需求分析说明书，完成激光打印机需求架构与规格定义；创新搭建三级需求分级管理模型，颗粒度细化至特性级，输出华为首版激光打印机三方合作 RFI 全维度规格书。针对行业核心痛点，设计耗材全生命周期管理方案，定义耗材芯片与设备 SOC 的交互逻辑，创新基于历史打印数据的余量预测算法、RFID 防伪方案与硒鼓粉盒联动阈值机制；主导半色调画质优化算法重构，完成图像预处理到打印输出的全链路画质优化，解决画面颗粒感强、还原度不足的用户痛点。

- 结果：打印机项目两大核心智能特性全量商用落地，相关体系沉淀为华为打印机品类研发与售后服务标准化模板；一线服务月人力投入从 10 人优化至 1.2 人，，耗材更换周期预测精度达 ±5%，打印图像还原度与用户满意度显著提升，打造了产品核心智能化竞争力。键鼠穿越特性成功商用，相关技术获发明专利授权，成为多屏协同生态核心差异化卖点。

四、技能证书 ----------

1. 硬技能：

- 编程语言和 AI 框架：Python、C++、SQL、Hive、PyTorch、TensorFlow、Transformer、Flash Attention
- 算法能力：机器学习/深度学习建模、运筹优化建模、大模型推理优化、算子开发及网络调优

2. 软技能：用户需求拆解与产品规划、数据驱动的产品迭代、复杂系统问题拆解与算法创新、跨团队技术协同与需求对齐

3. 所获证书：华为终端软件通用软件二级任职资格（15A）、CAIE 证书

五、其他亮点 ----------

1. 科研经历：以*第一作者发表 SCI 二区论文*《Impact of the Electric Vehicle Policies on Environment and Health in the Beijing–Tianjin–Hebei Region》，构建多模型综合分析框架，填补区域政策量化研究空白，研究成果为国家政策制定提供核心数据支撑；硕士毕业设计为*日本国立环境研究所专项课题，首次结合 CGE 模型与机器学习方法完成碳税政策量化评估*，核心结论被行业参考。

2. 实习经验：曾任职*阿里巴巴本地生活数据研发工程师助理、字节跳动经营分析部数据分析实习生*，具备 TB 级/亿级数据处理与业务分析能力，主导的用户增长策略推动核心指标提升 12%+。

3. 专利发明：已获国家发明专利授权 1 项，专利名称：一种基站智能供配电方法、装置及存储介质，专利 ID：202510828251.7